

SCALABLE AND RELIABLE SERVICES

REPORT

Design and development of a scalable and reliable service:

courtsight

Performed by:

Leonardo Baraldi, Riccardo Barbieri
Leonardo Ruberto, Gabriele Tassinari

Date: July 2024

Indice

1	Modello di predizione	2
1.1	Introduzione	2
1.2	Il Modello di Classificazione	2
1.2.1	MLP	2
1.3	I Modelli di Regressione	4
1.3.1	Analisi delle metriche	4
1.3.2	KNN	4
1.3.3	SVM	5
1.3.4	Random Forest	6
1.3.5	XGBoost	6
1.3.6	Bayesian	7
1.3.7	Linear Regression	8
1.4	I Risultati	8
1.5	Importanza Metriche	10
2	Middleware	10
2.1	Swagger OAS 3.0	11
2.2	Bet API	12
2.2.1	Endpoint	12
2.2.2	Dettagli implementativi	13
2.2.3	Quote storiche	13
2.3	NBA Api	14
2.3.1	Endpoint	14
2.3.2	Dettagli implementativi	15
2.3.3	Dati di allenamento del modello	15
3	Webapp	15
4	Deployment	15
4.1	Componenti	15
4.2	Servizi Azure	16
4.2.1	Container	16
4.2.2	Web Application	16
4.2.3	Modello Machine Learning	17
4.2.4	Servizi di supporto	17

1 Modello di predizione

1.1 Introduzione

L'obiettivo principale di questo progetto è sviluppare un modello di machine learning capace di predire l'esito delle partite NBA. Questo rappresenta una sfida ambiziosa che richiede un'analisi approfondita delle statistiche delle squadre e l'applicazione di avanzate tecniche di machine learning. Il dataset utilizzato comprende un array di statistiche per ciascuna squadra, sia per la squadra di casa che per quella in trasferta.

Sono stati testati sette differenti modelli sul set di training: Multi-Layer Perceptron (MLP), Random Forest, Support Vector Machine (SVM), XGBoost, Regressione Lineare, Modello Bayesiano e K-Nearest Neighbors (KNN).

Per sviluppare un modello competitivo rispetto alle soluzioni attualmente disponibili sul mercato, è stato inizialmente affrontato il problema come una questione di classificazione, utilizzando un MLP. Dato che i risultati ottenuti erano promettenti, sono state poi esplorate ulteriori possibilità per migliorare le prestazioni del modello. Di conseguenza, è stato convertito il problema di classificazione in un problema di regressione, con l'obiettivo di prevedere non solo l'esito (vittoria o sconfitta) ma anche il margine di punti con cui una squadra vince o perde.

L'approccio di regressione offre un livello di dettaglio superiore, consentendo non solo di determinare il vincitore della partita, ma anche di fornire una stima più precisa delle prestazioni delle squadre. Questa dualità di approccio, classificazione e regressione, ci permette di ottenere un modello robusto e versatile, in grado di adattarsi a diverse esigenze di predizione nel contesto delle partite NBA.

In sintesi, il progetto si articola in due fasi principali:

1. Creazione e valutazione di un modello di classificazione tramite MLP.
2. Espansione del modello in un contesto di regressione per migliorare la precisione delle predizioni.

I risultati ottenuti dalle varie sperimentazioni con i diversi modelli saranno discussi nelle sezioni successive, evidenziando i vantaggi e le limitazioni di ciascun approccio.

1.2 Il Modello di Classificazione

1.2.1 MLP

Introduzione al MLP Il Multi-Layer Perceptron (MLP) è una classe di reti neurali artificiali ampiamente utilizzata nei problemi di classificazione e regressione. Un MLP è composto da uno strato di input, uno o più strati nascosti e uno strato di output. Ogni nodo (o neurone) in uno strato è connesso a ciascun nodo nel successivo strato, rendendolo un tipo di rete completamente connessa. I MLP utilizzano la retropropagazione per allenare il modello, aggiornando i pesi dei neuroni in base all'errore commesso nelle predizioni.




Figura 1: Multi-Layer Perceptron

Sviluppo del Modello Il primo approccio analizzato è stato quello di creare un MLP per risolvere il problema di classificazione. Il primo passo è stato quello di effettuare il preprocessing dei dati, eliminando tutte le informazioni non necessarie per l'allenamento della rete o eliminando informazione che rendevano il modello meno accurato e dunque meno performante. In particolare, sono stati rimossi i seguenti campi:

```
['pts_H', 'pts_A', 'referee_id', 'winner', 'home_team', 'away_team', 'referee_name', 'season', 'date']
```

Inoltre prima di poter utilizzare il vettore finale, composto dunque dalle statistiche delle due squadre, per allenare il nostro modello, è stato necessario preprocessarlo. È stato quindi usato il `MinMaxScaler`, ovvero un algoritmo che garantisce che i valori fossero compresi tra -1 e 1, questo ha portato notevoli miglioramenti sia in termini di accuracy del modello sia in termini di performance della rete.

Struttura del Modello Il modello di machine learning è stato quindi costruito utilizzando tre strati `Dense`, ovvero strati fortemente connessi in grado di apprendere dai dati in input per ottenere un preciso output. La rete neurale ottenuta è stata quindi addestrata, come consuetudine, utilizzando l'80% del Dataset suddiviso il Train Set e Validation Set. Per migliorare ulteriormente il modello è stato eseguito un processo di fine-tuning manuale per massimizzare l'accuratezza.




Figura 2: Pre Fine-Tuning e Overfitting




Figura 3: Post Fine-Tuning

Inizialmente, è stato utilizzato un *batch size* di 16 e sono state impostate 800 epoche per monitorare la funzione di *loss* e identificare il punto di *overfitting* del modello. Attraverso questo processo, è stato determinato che i parametri ideali per l'allenamento erano 300 epoche e un *batch size* di 32.

Risultati Prima di poter analizzare questo risultato occorre precisare che l'accuracy fornita dai modelli citati online risulta essere tra il 62% ed il 66%. In particolare è presente un interessante articolo, redatto dalla Bryant University, nel quale presentano il loro modello che possiede una accuracy del 65%.

In quest'ottica è possibile dire che il nostro modello finale ha ottenuto un'accuratezza estremamente competitiva, ottenendo una accuracy del 69,92%, dimostrando così la validità dell'approccio MLP nel contesto della classificazione delle partite NBA. Questi risultati indicano che il nostro modello è in grado di fornire predizioni accurate (7 volte su 10) sulla vittoria o sconfitta delle squadre, basandosi sulle statistiche pre-partita.

In sintesi, l'implementazione del MLP come modello di classificazione ha fornito una solida base per ulteriori miglioramenti e ottimizzazioni, consentendo di esplorare ulteriori tecniche e modelli per migliorare le capacità predittive.

Results MLP:

Loss: 0.5629295706748962
Accuracy: 0.6992385983467102

1.3 I Modelli di Regressione

Il problema di classificazione è stato poi convertito in un problema di regressione, in modo da testare nuovi approcci e verificare se il modello ottenuto potesse essere ulteriormente migliorato. Tutti i modelli analizzati in questa sezione sono stati prima ottimizzati utilizzando una GridSearch per ottenere la combinazione ideale di iperparametri per ciascun modello. Verranno quindi analizzati i vari modelli e i risultati ottenuti, in ordine crescente di accuracy fornita.

1.3.1 Analisi delle metriche

Nel valutare le prestazioni del modello di regressione per la predizione dei risultati delle partite NBA, sono stati utilizzati diversi indicatori chiave di errore e precisione.

- **Mean Absolute Error (MAE):** Il MAE misura la deviazione media tra le predizioni del modello e i valori reali. Nel nostro caso, il MAE indica dunque l'errore medio tra la differenza di punti predetti dal modello e i risultati reali delle partite.
- **Mean Squared Error (MSE):** Il MSE misura la media dei quadrati delle differenze tra predizioni e valori reali. Il MSE evidenzia dunque una variabilità nelle differenze tra predizioni e valori reali rispetto al MAE.
- **Root Mean Squared Error (RMSE):** Il RMSE è la radice quadrata del MSE ed è espresso nelle stesse unità della variabile target. Nel nostro caso, il RMSE indica che in media le predizioni del modello hanno un errore di una certa quantità di punti rispetto ai risultati reali.
- **Sign Accuracy:** La Sign Accuracy rappresenta la precisione del modello nel predire correttamente la direzione (positiva o negativa) delle differenze tra predizioni e valori reali. Questa metrica misura se il segno tra la differenza dei punti predetti e quella reale è concorde, in modo da prevedere quindi il vincitore di una partita indipendentemente dalla differenza dei punti.

Queste metriche forniscono una valutazione completa delle performance del modello di regressione, evidenziando sia l'errore medio delle predizioni che la sua capacità di predire correttamente l'esito delle partite NBA. Il confronto tra MAE, MSE e RMSE fornisce una panoramica dell'accuratezza delle predizioni a diversi livelli di dettaglio, mentre la Sign Accuracy fornisce una misura della precisione nella classificazione della direzione delle differenze.

1.3.2 KNN

Il K-Nearest Neighbors (KNN) è un algoritmo di machine learning utilizzato per problemi di classificazione e regressione. Nel contesto della regressione, KNN prevede il valore di una variabile target basandosi sui valori medi dei k vicini più prossimi nel dataset di addestramento. La vicinanza tra i punti dati è solitamente calcolata tramite una metrica di distanza, come la distanza euclidea. KNN è semplice da implementare e interpretare, ma può essere computazionalmente costoso per dataset di grandi dimensioni.

Il modello KNN è stato valutato utilizzando diverse metriche di errore, ottenendo i seguenti risultati:

Mean Absolute Error (MAE): 11.620278833967047
Mean Squared Error (MSE): 215.66732572877058
Root Mean Squared Error (RMSE): 14.6856162869922
Sign Accuracy: 0.6172370088719898

Il modello ha raggiunto un'accuratezza del 61,72%.

Sono stati estratti 10 match casuali dal test set per valutare le prestazioni del modello, ottenendo i seguenti risultati:




Figura 4: Comparazione differenza punti predetti rispetto a reali in KNN

1.3.3 SVM

Il modello SVM ha mostrato un'accuratezza migliore rispetto ad altri approcci. SVM (Support Vector Machine) è un algoritmo di apprendimento supervisionato utilizzato per la classificazione e la regressione. Esso cerca di trovare il miglior iperpiano o separatore tra i punti dei dati delle diverse classi. Nella figura sottostante è rappresentato un esempio di SVM con due classi.

Questo modello ha ottenuto i seguenti risultati nei test:

Mean Absolute Error (MAE): 10.360566704859455

Mean Squared Error (MSE): 173.73226432418772

Root Mean Squared Error (RMSE): 13.18075355676555

Sign Accuracy: 0.6806083650190115

Il modello ha raggiunto un'accuratezza del 68.06%. Inoltre, sono stati estratti 10 match casuali dal set di test per valutare ulteriormente le prestazioni del modello:




Figura 5: Comparazione differenza punti predetti rispetto a reali in SVM

Questi risultati dimostrano che il modello SVM ha mostrato una buona capacità predittiva per l'esito delle partite NBA, con una precisione significativa e una buona gestione della variazione nei dati di test.

1.3.4 Random Forest

Il Random Forest è un metodo di apprendimento ensemble utilizzato per la classificazione e la regressione. Esso costruisce diversi alberi decisionali e li combina per ottenere previsioni più accurate. In un random forest, solo un sottoinsieme delle caratteristiche è considerato dall'algoritmo per dividere un nodo. Il modello classificherà anche l'importanza di ciascuna caratteristica nel prendere la decisione finale. Nella figura sottostante c'è un esempio di random forest con due alberi.

Questo modello ha ottenuto risultati soddisfacenti nei test, come mostrato di seguito:

Mean Absolute Error (MAE): 9.944223032615545
Mean Squared Error (MSE): 159.938928930258
Root Mean Squared Error (RMSE): 12.646696364278617
Sign Accuracy: 0.6958174904942965

Il modello ha raggiunto un'accuratezza del 69.58%. Inoltre, sono stati estratti 10 match casuali dal set di test per valutare ulteriormente le prestazioni del modello:




Figura 6: Comparazione differenza punti predetti rispetto a reali in Random Forest

Questi risultati indicano che il modello Random Forest ha dimostrato di essere efficace nel predire l'esito delle partite NBA, con un'accuratezza significativa e una buona capacità di generalizzazione su nuovi dati di test.

1.3.5 XGBoost

XGBoost è un algoritmo di boosting estremamente popolare e efficace utilizzato per la classificazione e la regressione. Utilizza un insieme di alberi decisionali deboli, chiamati "weak learners", e li combina per migliorare progressivamente le prestazioni del modello.

Questo modello ha ottenuto i seguenti risultati nei test:

Mean Absolute Error (MAE): 9.6111730557072
Mean Squared Error (MSE): 149.89162676035912
Root Mean Squared Error (RMSE): 12.243023595515902
Sign Accuracy: 0.7046894803548795

Il modello ha raggiunto un'accuratezza del 70.47%. Inoltre, sono stati estratti 10 match casuali dal set di test per valutare ulteriormente le prestazioni del modello:




Figura 7: Comparazione differenza punti predetti rispetto a reali in XGBoost

Questi risultati indicano che il modello XGBoost ha dimostrato di essere altamente efficace nel predire l'esito delle partite NBA, con un'accuratezza significativa e una buona capacità di generalizzazione su nuovi dati di test. L'utilizzo di boosting ha permesso al modello di migliorare costantemente la precisione delle predizioni, rendendolo una scelta potente per problemi complessi come quello delle previsioni sportive.

1.3.6 Bayesian

Il modello Bayesian utilizza l'inferenza Bayesiana per stimare parametri incogniti. È particolarmente utile quando si hanno dati limitati e si desidera incorporare conoscenze pregresse o informative nel modello.

Questo modello ha ottenuto i seguenti risultati nei test:

Mean Absolute Error (MAE): 9.684169695449112

Mean Squared Error (MSE): 151.8468062429373

Root Mean Squared Error (RMSE): 12.322613612498662

Sign Accuracy: 0.7072243346007605

Il modello ha raggiunto un'accuratezza del 70.72%. Inoltre, sono stati estratti 10 match casuali dal set di test per valutare ulteriormente le prestazioni del modello:




Figura 8: Comparazione differenza punti predetti rispetto a reali in Bayesian

Questi risultati indicano che il modello Bayesian ha mostrato una buona capacità predittiva per l'esito delle partite NBA, con un'accuratezza significativa e una robusta gestione dell'incertezza nei dati.

di test. L'approccio basato sull'inferenza Bayesiana ha permesso al modello di integrare informazioni a priori con i dati osservati, migliorando così le performance complessive delle previsioni.

1.3.7 Linear Regression

La regressione lineare è un modello di machine learning che cerca di trovare la relazione lineare migliore tra una variabile dipendente (target) e una o più variabili indipendenti (features). È un metodo semplice ma potente per la predizione numerica.

Questo modello ha ottenuto i seguenti risultati nei test:

Mean Absolute Error (MAE): 9.673524553632301

Mean Squared Error (MSE): 151.58868540348476

Root Mean Squared Error (RMSE): 12.312135696274824

Sign Accuracy: 0.7135614702154626

Il modello ha raggiunto un'accuratezza del 71.36%. Inoltre, sono stati estratti 10 match casuali dal set di test per valutare ulteriormente le prestazioni del modello:




Figura 9: Comparazione differenza punti predetti rispetto a reali in Linear Regression

Questi risultati indicano che il modello di Regressione Lineare ha mostrato una buona capacità predittiva per l'esito delle partite NBA, con un'accuratezza significativa e un'efficace modellazione della relazione lineare tra le variabili di input e il target. La semplicità e la trasparenza della regressione lineare lo rendono un buon punto di partenza per esplorare i modelli di previsione numerica nelle analisi sportive.

1.4 I Risultati

È dunque possibile ora analizzare i dati in maniera unitaria e completa. Per effettuare ciò occorre suddividere l'analisi dei risultati in due distinte sezioni, una per analizzare i risultati inerenti al problema di classificazione: Vittoria o Sconfitta, ed un'altra per analizzare i risultati del problema di regressione.

Inerentemente al problema di classificazione, per gli algoritmi di regressione è stata creata una nuova metrica fittizia denominata sign accuracy che ci ha permesso di convertire il problema di regressione in classificazione. Comparando così le varie sign accuracy ottenute con i vari algoritmi, otteniamo il seguente risultato.

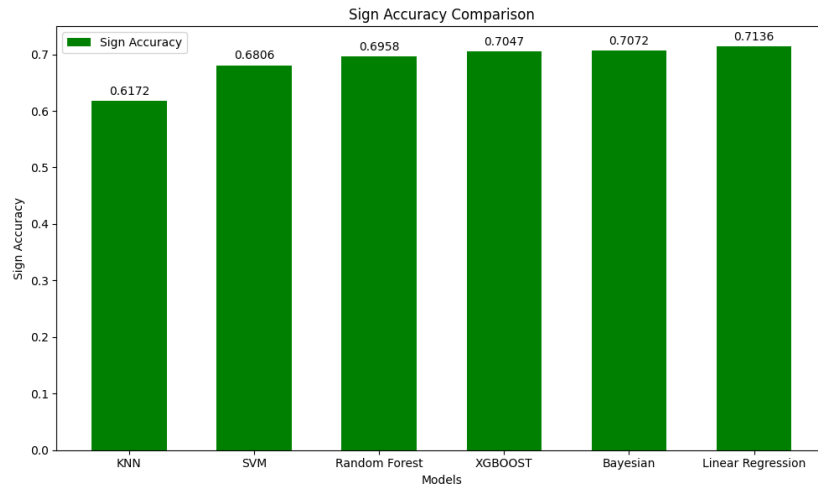


Figura 10: Sign accuracy a confronto

È possibile notare che l'algoritmo che ci fornisce una sign accuracy migliore è il Linear Regression che totalizza una accuracy del 71,36%. Questo è poi seguito dal Bayesian Regressor con 70,72% e dal XGBoost Regressor con 70,46%. Questi risultati algoritmi sono quindi riusciti ad ottenere, a parità di input, un risultato migliore anche del modello MLP creato. In ultima posizione vediamo come il K-Nearest Neighbor abbia le prestazioni peggiori.

Concentrandoci ora sull'analisi del problema di regressione e dunque sull'analisi della differenza tra i punti predetti ed i punti reali otteniamo risultati leggermente diversi. A tal proposito è stata confrontata la metrica: Mean Absolute Error, ovvero la metrica in grado di dare informazioni riguardanti l'errore medio dei vari modelli creati. Confrontando così questa metrica sono stati ottenuti questi risultati.




Figura 11: Caption

L'algoritmo in termini di regressione più performante risulta essere XGBoost con 9,61 punti di scarto medio, seguito poi dalla Linear Regression con 9,67 punti e dal Bayesian con 9,68. Il K-Nearest Neighbor al contrario continua a confermarsi il meno performante con 11,62 punti di scarto medio.

1.5 Importanza Metriche

I modelli di regressione sono stati poi confrontati per comprendere quali fossero le features che ciascun modello usava ed analizzava maggiormente per prevedere la differenza di punteggio delle partite. Nella figura sottostante sono messi a confronto i 3 modelli migliori (ovvero bayesian, xgboost e linear regression) ed il modello peggiore ovvero KNN.




Figura 12: Bayesian




Figura 13: Linear Regression




Figura 14: XGBoost




Figura 15: K-Nearest Neighbors

Si può vedere come i 3 modelli migliori (ovvero bayesian, xgboost e linear regression) valutano maggiormente e dunque prediligono le seguenti metriche:

- lineup_efficiency_A
- lineup_efficiency_H
- off_rating_A
- off_rating_H
- def_rating_H
- def_rating_A

Al contrario del modello di regressione K-Nearest Neighbors che mantiene solo le lineup_efficiency ed altre feature a scapito di: off_rating_A off_rating_H def_rating_A def_rating_H

2 Middleware

L'obiettivo del nostro progetto era realizzare un servizio web per fornire statistiche sui match NBA e provare a predirne i risultati. Abbiamo esteso questa idea creando un'applicazione web (analizzata in

seguito) che permettesse non solo di prevedere l'esito di un match NBA, ma anche di fornire tutte le informazioni necessarie per valutare personalmente quale squadra avesse maggiori probabilità di vincere, includendo anche le quote offerte dai bookmakers. In pratica, il nostro progetto si è avvicinato alla realizzazione di un sito di scommesse con l'aggiunta di informazioni e previsioni sui match, limitato al contesto NBA.

Per realizzare questa applicazione web, abbiamo avuto bisogno di due tipi di informazioni principali:

- Dati statistici sui match, sui team e sui giocatori (limitati al contesto della NBA).
- Informazioni sulle quote delle scommesse head-to-head e spread (head-to-head con handicap).

2.1 Swagger OAS 3.0

Abbiamo deciso di implementare i nostri middleware come server REST API, poiché questo è uno standard affermato per la creazione di servizi web che offre benefici come flessibilità, scalabilità e facilità di manutenzione. Per implementare e documentare le nostre API in modo efficiente, abbiamo scelto di utilizzare l'Open API Specification 3.0 (OAS 3.0).

La specifica OAS 3.0 ci ha permesso di descrivere in dettaglio tutti gli endpoint disponibili, inclusi i parametri, le risposte (sia di successo che di errore) e i tipi di oggetti restituiti, con esempi dettagliati. Abbiamo utilizzato i servizi offerti da Swagger per generare automaticamente un'interfaccia utente che ci ha permesso di testare le nostre API con facilità, inizialmente basandoci solo sulla specifica testuale e ottenendo risposte fittizie, e successivamente utilizzando il progetto completo per ottenere risposte reali basate sulla logica di backend presente dietro ciascuno degli endpoint.

Questo approccio ci ha permesso di facilitare notevolmente lo sviluppo e la coordinazione tra i membri del team. È stato sufficiente definire la specifica testuale per permettere a chi sviluppava l'applicazione web e a chi implementava i middleware di lavorare in modo indipendente, basandosi semplicemente sulla specifica OAS definita in precedenza. Inoltre, Swagger ci ha permesso di generare gli scheletri dei server REST API in modo automatizzato, prendendo in input solo la specifica testuale. Questo ci ha dato un enorme vantaggio sia iniziale, per realizzare il progetto senza partire da zero, sia in termini di estensibilità futura. Per aggiungere nuovi endpoint, possiamo farli generare dallo stesso servizio e copiare nel nostro progetto solo le parti nuove, con uno sforzo di implementazione minimo.

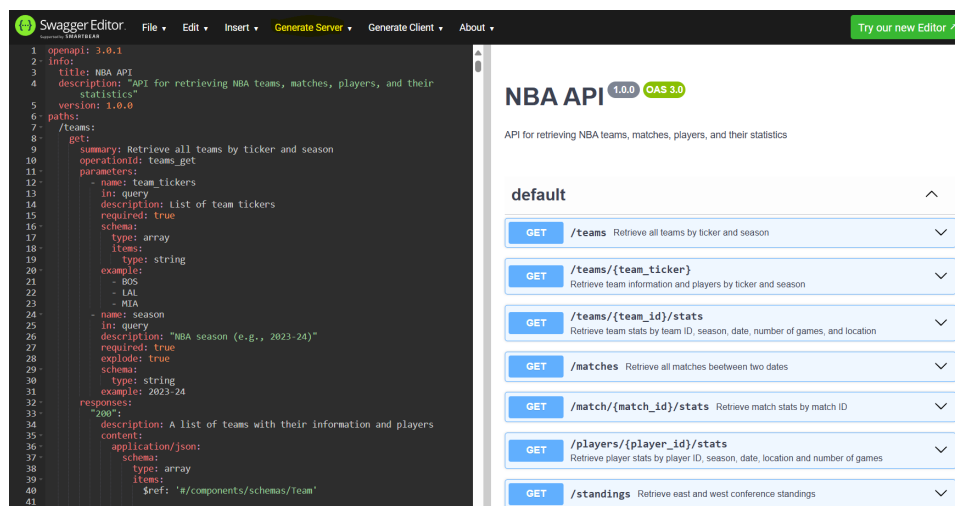


Figura 16: Interfaccia utente Swagger UI per testing e generazione server

2.2 Bet API

Partiamo dall'analisi della `bet_api`, ovvero del servizio che permette alla `web app` di ottenere tutte le informazioni necessarie relative alle quote dei match. Alla base di questa API è presente un'ulteriore API, che analizza tutti i siti dei bookmakers di varie regioni del mondo e restituisce le quote di ogni partita, relative a diversi mercati: The Odds API.

Il concetto di middleware entra in gioco qui: avremmo potuto utilizzare direttamente l'API già esistente per ottenere tutte le informazioni di nostro interesse, ma così facendo abbiamo potuto semplificare gli endpoint, limitandoli alle sole informazioni di nostro interesse e richiedendo solo i parametri di input strettamente necessari. Inoltre, abbiamo centralizzato la gestione della sicurezza, sollevando la `web app` dal memorizzare e inviare ogni volta la API key per autenticarsi presso la Odds API.

The Odds API fornisce le quote non solo per la NBA, ma per qualsiasi sport presente su un sito di scommesse. Questo ci ha permesso di estendere ulteriormente le funzionalità della nostra applicazione e di realizzare di conseguenza il middleware `bet_api`. Abbiamo scelto di strutturare gli endpoint in modo da supportare qualsiasi tipo di sport, senza limitarci alla sola NBA di nostro interesse iniziale. Questo comporta un minimo overhead in termini di complessità, ma offre grande flessibilità.

In questo modo, la nostra `web app` è in grado di supportare e visualizzare all'utente le quote di qualsiasi sport presente su un sito di scommesse, sempre limitate ai due mercati principali head-to-head e spread, che sono comuni alla maggior parte degli sport. Questo ci consente di estendere in futuro il nostro servizio aggiungendo statistiche e previsioni relative anche ad altri sport.

2.2.1 Endpoint

Di seguito vengono presentati gli endpoint disponibili:

- `/sports/getSportGroups`

Restituisce l'elenco di tutti i gruppi sportivi disponibili. Questo endpoint supporta un parametro opzionale: `all`, che se impostato a `true` restituisce sia i gruppi sportivi in stagione che quelli fuori stagione. La risposta di successo, con codice 200, contiene un elenco di tutti i gruppi sportivi disponibili.

- `/sports/getSports`

Restituisce l'elenco di tutti gli sport disponibili. Questo endpoint supporta due parametri opzionali: `groupName`, che consente di filtrare gli sport per nome del gruppo, e `all`, che se impostato a `true` restituisce sia gli sport in stagione che quelli fuori stagione. La risposta di successo, con codice 200, contiene un elenco di tutti gli sport disponibili.

- `/sports/getSportEvents`

Restituisce l'elenco di tutti gli eventi disponibili per uno sport specifico. È necessario specificare il parametro obbligatorio `sportKey`, che indica la chiave dello sport degli eventi. Sono supportati due parametri opzionali: `commenceTimeFrom` e `commenceTimeTo`, che permettono di filtrare gli eventi in base al loro orario di inizio e di fine. La risposta di successo, con codice 200, contiene un elenco di tutti gli eventi disponibili.

- `/odds/head2head`

Restituisce le migliori quote head-to-head per un evento specifico. È necessario specificare i parametri obbligatori `eventId` e `sportKey`, che indicano rispettivamente l'ID dell'evento e la chiave dello sport dell'evento. È disponibile un parametro opzionale `regions`, che consente di specificare la regione per ottenere le quote. La risposta di successo, con codice 200, contiene un elenco delle migliori quote head-to-head.

- **/odds/spreads**

Restituisce le migliori quote head-to-head con handicap per un evento specifico. È necessario specificare i parametri obbligatori **eventId** e **sportKey**, che indicano rispettivamente l'ID dell'evento e la chiave dello sport dell'evento. È disponibile un parametro opzionale **regions**, che consente di specificare la regione per ottenere le quote. La risposta di successo, con codice 200, contiene un elenco delle migliori quote head-to-head con handicap.

Per ciascuno degli endpoint presentati sopra, sono previste risposte con codice 201 nel caso in cui non ci siano quote, eventi o sport da restituire, con codice di errore 400 per richieste errate e 500 per errori interni del server.

Da notare come, oltre al supporto per tutti gli sport grazie al parametro chiave **sportKey** (che avremmo potuto omettere inserendo sempre la chiave relativa all'NBA), vi è anche una logica per la restituzione delle quote per ogni match, ordinate dalla più vantaggiosa per l'utente, prendendo in considerazione tutti i siti di scommesse disponibili. In questo modo, tramite la web app, l'utente può avere una visione completa delle quote disponibili per ogni match e scegliere quella che ritiene più conveniente basandosi sui siti di scommesse sui quali ha un conto aperto.

Inoltre, abbiamo reso disponibili per l'utente i link ai vari siti di scommesse, in modo da facilitarne l'accesso e il controllo della quota mostrata. Per ottenere questa informazione, non disponibile direttamente da **The Odds API**, abbiamo effettuato dello scraping direttamente sul web, basandoci sul nome del sito fornito appunto dall'API.

Nota: Il file `bet_oas.yaml` presenta la specifica Open API 3.0 completa, utilizzata per generare il server iniziale.

2.2.2 Dettagli implementativi

A livello implementativo, è stato usato Spring Boot per costruire il middleware, sfruttando la potenza delle sue annotazioni per ottenere un codice altamente strutturato, pulito e flessibile.

Inoltre, è importante sottolineare l'uso dell'autenticazione con **The Odds API** tramite **API Key**. Abbiamo sfruttato il concetto di *Interceptor* di Spring, un componente che si interpone prima di ogni *HttpRequest* e tramite il quale è possibile modificare i parametri e l'header della richiesta. Questo ci ha permesso di omettere sia il link della **Odds API** sia la **API Key** in ogni richiesta, poiché queste informazioni sono state salvate nel *context* dell'applicazione e aggiunte automaticamente ad ogni richiesta in uscita.

Quindi, in caso di aggiornamenti dell'URL o di rinnovo dell'**API Key**, sarà sufficiente modificare il codice in un solo punto, senza dover cercare e modificare ogni singola chiamata, portando grandi vantaggi in termini di manutenibilità.

2.2.3 Quote storiche

Il piano gratuito di **The Odds API** non ci permette purtroppo di ottenere dati su eventi e quote storiche (già passate). Questo ci ha posto dei limiti nelle ultime fasi di sviluppo poiché, essendo terminata la stagione NBA, play-off compresi, non abbiamo potuto utilizzare i dati per mostrarli all'interno dell'applicazione.

Per far fronte a questo problema, abbiamo deciso di implementare una logica che ritorna delle quote fittizie, ma verosimili, per partite passate e per le quali i bookmakers non mantengono più le quote online.

Ovviamente, ciò non toglie il fatto che per tutti gli sport e competizioni per i quali sono presenti match in corso (o più in generale per le quali i bookmakers pubblicano le quote), la logica applicativa ritorna le quote reali.

2.3 NBA Api

Il middleware `nba_api` è, come anticipato, un REST API Server che si pone l'obiettivo di interfacciarsi con per ottenere informazioni statistiche relative a partite, squadre e giocatori dell'NBA.

Anche in questo caso, il middleware ha lo scopo di facilitare l'interazione con `swar/nba_api`, diminuendo di gran lunga la complessità ed esponendo degli endpoint mirati e di facile comprensione.

2.3.1 Endpoint

Di seguito vengono presentati gli endpoint disponibili:

- `/teams` Restituisce l'elenco di tutte le squadre con il ticker e la stagione. Questo endpoint supporta due parametri obbligatori: `team_tickers`, che è una lista dei ticker delle squadre, e `season`, che specifica la stagione NBA. La risposta di successo, con codice 200, contiene un elenco di tutte le squadre con le relative informazioni e giocatori.
- `/teams/team_ticker` Restituisce le informazioni della squadra e dei giocatori per un ticker di squadra specifico e una stagione. È necessario specificare il parametro obbligatorio `team_ticker`, che indica il ticker della squadra, e `season`, che specifica la stagione NBA. La risposta di successo, con codice 200, contiene le informazioni della squadra e un elenco di giocatori.
- `/teams/team_id/stats` Restituisce le statistiche della squadra per ID, stagione, data, numero di partite e luogo. È necessario specificare i parametri obbligatori `team_id`, che indica l'ID della squadra, `season`, che specifica la stagione NBA, e `date_to`, che specifica la data fino alla quale considerare le statistiche. Sono supportati due parametri opzionali: `last_x`, che specifica il numero di ultime partite da considerare, e `home_away_filter`, che specifica il luogo delle partite (HOME o AWAY). La risposta di successo, con codice 200, contiene un elenco di statistiche della squadra.
- `/matches` Restituisce l'elenco di tutte le partite tra due date. È necessario specificare il parametro obbligatorio `date_from`, che indica la data di inizio delle partite da considerare. È disponibile un parametro opzionale `date_to`, che specifica la data di fine delle partite da considerare. La risposta di successo, con codice 200, contiene un elenco di tutte le partite.
- `/match/match_id/stats` Restituisce le statistiche della partita per un ID partita specifico. È necessario specificare il parametro obbligatorio `match_id`, che indica l'ID della partita, e `match_date`, che specifica la data della partita. La risposta di successo, con codice 200, contiene le statistiche della partita.
- `/players/player_id/stats` Restituisce le statistiche del giocatore per ID, stagione, data, luogo e numero di partite. È necessario specificare i parametri obbligatori `player_id`, che indica l'ID del giocatore, `season`, che specifica la stagione NBA, e `date_to`, che specifica la data fino alla quale considerare le statistiche. Sono supportati due parametri opzionali: `last_x`, che specifica il numero di ultime partite da considerare, e `home_away_filter`, che specifica il luogo delle partite (HOME o AWAY). La risposta di successo, con codice 200, contiene le statistiche del giocatore.
- `/standings` Restituisce la classifica delle conferenze est e ovest. È necessario specificare il parametro obbligatorio `date`, che indica la data da considerare per valutare la classifica. La risposta di successo, con codice 200, contiene la classifica delle conferenze est e ovest.
- `/feature_vector` Restituisce il vettore caratteristico. È necessario specificare i parametri obbligatori `team_ticker`, che indica il ticker della squadra, `opp_team_ticker`, che specifica il ticker della squadra avversaria, `season`, che specifica la stagione NBA, e `date`, che specifica la data della partita. La risposta di successo, con codice 200, contiene il vettore caratteristico.

- `/score` Restituisce il punteggio su un vettore caratteristico. La richiesta deve contenere un `feature_vector` nel corpo della richiesta. La risposta di successo, con codice 200, contiene un punteggio più o meno.

2.3.2 Dettagli implementativi

Anche questo middleware è stato realizzato tramite la generazione assistita di Swagger Editor.

Tuttavia, per poter utilizzare le librerie Python di `swar/nba_api`, abbiamo dovuto utilizzare un ambiente Python con `Flask`.

Oltre alla facilitazione già fornita da Swagger, tramite Python è stato possibile mappare gli endpoint ai metodi direttamente dalla specifica YAML, aggiungendo qualche campo in più. Questo ha aumentato di gran lunga la manutenibilità e l'estensibilità del middleware. L'aggiunta di nuovi endpoint nel corso dello sviluppo ha comportato solo l'inserimento dei percorsi nel codice Swagger e l'implementazione delle funzioni con la logica applicativa necessaria.

2.3.3 Dati di allenamento del modello

Lo scopo di questo middleware non è solo quello di fornire degli endpoint per l'applicazione web. Infatti, grazie all'implementazione di metodi comuni e all'utilizzo delle librerie di `swar/nba_api`, sono state aggiunte parti di codice volte a popolare il database di allenamento del modello di machine learning per la previsione dell'esito delle partite.

Oltre alla grande comunanza di codice, questa scelta è stata fatta anche per un miglioramento delle prestazioni, particolarmente a lungo termine, tramite l'uso della `cache` per i metodi della libreria.

Come sviluppo futuro, non realizzato per mancanza di tempo, si potrebbe pensare di dividere questo middleware in tre microservizi: un REST API Server che utilizza le librerie di `swar/nba_api` e che fornisce endpoint per gli altri due microservizi, il primo che funge da middleware per l'applicazione e il secondo che si occupa di ottenere i dati e popolare il database di allenamento del modello di machine learning.

3 Webapp

4 Deployment

In questa sezione verranno trattate le scelte in materia di deployment dell'architettura, discuteremo le scelte effettuate per i servizi Azure utilizzati, la configurazione di tali servizi e l'automazione del processo di deployment, così come le soluzioni e strategie adottate per garantire scalabilità e affidabilità dell'applicazione.

4.1 Componenti

Per riferimento si riportano di seguito i componenti principali che costituiscono l'applicazione.

- Middleware NBA Api
- Middleware Bet Api
- Frontend Applicazione Web
- Modello Machine Learning

Abbiamo preso la decisione di creare dei middleware per l'interazione con le api delle quote e delle statistiche NBA per creare una interfaccia che permette alla applicazione di non essere a conoscenza del

funzionamento delle API sottostanti che forniscono i dati, questo approccio permetterà inoltre in futuro di modificare le API sottostanti per migliorare le prestazioni dell'applicazione.

L'applicazione deve essere in grado di adattarsi ad aumenti inaspettati del carico di richieste, per questo è stato necessario utilizzare servizi che supportassero funzionalità di scalabilità automatiche sia all'aumento del carico, sia alla sua diminuzione per mantenere il più possibile contenuti i costi del servizio.

Per la distribuzione dei due middleware abbiamo deciso di utilizzare container OCI in quanto sono lo strumento più adatto a effettuare il deployment di una architettura a microservizi.

4.2 Servizi Azure

Microsoft Azure offre una vasta gamma di servizi per qualsiasi tipo di deployment, la scelta del giusto servizio per un certo componente è cruciale per bilanciare costi di operazione del componente e massimizzare l'efficienza e automazione del processo di deployment minimizzando le interruzioni del servizio.

4.2.1 Container

Microsoft Azure offre varie opzioni per il deployment di componenti basati su container OCI, da cluster Kubernetes parzialmente gestiti a ambiente completamente gestiti:

- Azure Container Instances (ACI)
- Azure Container Apps (ACA)
- Azure Kubernetes Services (AKS)
- Azure App Service (AAS)

Questi servizi hanno diversi livelli di complessità delle opzioni di configurazione, in particolare AKS è il servizio che offre la maggiore granularità nelle opzioni di gestione dei cluster di container: si tratta di una istanza di Kubernetes gestita da Azure che fornisce una piattaforma di orchestrazione completa adatta a deployment molto complessi.

Durante la valutazione delle opzioni abbiamo escluso il servizio AAS in quanto si tratta di un servizio non nativamente improntato a deployment di applicazioni sotto forma di container, non offre infatti le opzioni di gestione della scalabilità offerte da altri servizi concepito per container.

Mentre ACI offre una esperienza di deployment molto semplificata non dà la possibilità di creare regole di scaling e replicazione personalizzate, ogni aspetto del deployment è gestito da Azure; ACA si pone a metà strada tra la semplicità di ACI e la complessità di AKS in quanto nasconde dettagli di gestione del cluster Kubernetes ma permette comunque di specificare regole e limiti di scaling con abbastanza granularità.

Abbiamo infine deciso di utilizzare Azure Container Apps per il deployment dei due microservizi.

Abbiamo distribuito i componenti middleware in un unico Azure Container App Environment, il componente che orchestra le ACA mantenendo aggiornamenti OS, procedure di recupero post-failure e bilanciamento delle risorse tra componenti, questo servizio gestisce inoltre la creazione e configurazione del virtual network che si pone a protezione delle ACA istanziate.

4.2.2 Web Application

Per effettuare il deployment dell'applicazione web abbiamo ristretto l'offerta di Azure a due servizi:

- Azure Static Web App (SWA)
- Azure App Service (AAS)

Come in precedenza il servizio AAS risulta non adatto agli scopi dell'applicazione in quanto l'applicazione necessita solo di un frontend che comunica con i due microservizi, abbiamo quindi deciso di utilizzare il servizio SWA, un servizio che offre la possibilità di distribuire una webapp statica con gestione automatica di un CDN globale per garantire una distribuzione del contenuto veloce e affidabile.

Questo servizio offre anche la possibilità di associare un backend sotto forma di ACA o Azure Functions: in futuro sarà possibile aggiungere un nuovo microservizio che gestisca il backend dell'applicazione, implementando funzionalità come la creazione account utente.

4.2.3 Modello Machine Learning

Per rendere il modello accessibile al componente che ne deve mostrare i risultati abbiamo valutato diverse opzioni per creare appositi endpoint per richiedere una inferenza al modello.

La prima opzione che abbiamo considerato è stata creare un container apposito e utilizzare una ACA per rendere gli endpoint accessibili al frontend dell'applicazione, per quanto questa possa essere una soluzione appropriata in quanto avrebbe reso più uniforme l'architettura che fa già largamente uso di ACA, Azure offre una soluzione migliore apposita per modelli di machine learning.

Azure Machine Learning Workspace mette a disposizione un ambiente completamente fornito per ogni step della creazione e gestione di un modello di machine learning.

Le funzionalità principali che sono risultate utili sono le seguenti:

- ambienti di sviluppo gestiti e configurabili
- categorizzazione e versioning dei modelli creati
- authoring di modelli tramite jupyter notebooks e strumenti di alto livello a componenti
- riusabilità dei componenti
- gestione automatica della cache di inferenze passate
- valutazione delle performance del modello tramite strumenti di analisi

Questo workspace permette inoltre di effettuare deployment dei modelli creati e di generare appositi endpoint HTTP per richiedere l'inferenza su una istanza del feature vector in modo sicuro, autenticando le richieste tramite chiavi api.

Durante il deployment del modello abbiamo riscontrato problematiche con la gestione delle politiche CORS: il sistema di deployment integrato non supporta la modifica delle politiche CORS per abilitare l'accesso da parte di una applicaizione web. Per risolvere questo problema abbiamo integrato questo endpoint in un endpoint presente nel Middleware NBA Api.

4.2.4 Servizi di supporto

I servizi appena descritti includono i componenti principali dell'applicazione, abbiamo però utilizzato diversi altri servizi Azure di supporto.

Gestione segreti Una necessità immediatamente evidente durante lo sviluppo è stata quella di avere a disposizione un sistema centralizzato dove archiviare in modo sicuro vari segreti come chiavi api e certificati. Si presta a questo scopo il servizio Azure Key Vault che offre la possibilità di immagazzinare segreti gestendone il versionamento di questi ultimi.

Un'altra funzionalità che Key Vault offre è la possibilità di impostare la rotazione automatica di certificati crittografici, sfruttata dal sistema per rinnovare automaticamente i certificati legati al dominio personalizzato usato per raggiungere l'applicazione.

Gestione Immagini OCI Il sistema sfrutta diverse immagini OCI e deve essere in grado di gestirne il versionamento mantenendole private.

A questo scopo abbiamo sfruttato due istanze di Azure Container Registry, un servizio che offre la possibilità di immagazzinare definizioni di immagini con gestione delle versioni tramite tag, è inoltre meglio integrato con gli altri servizi di Azure di altri container registry.

Le credenziali per l'accesso all'istanza ACR principale, ovvero quella che contiene le immagini dei middleware, sono gestite tramite Azure Key Vault; la seconda istanza, dedicata alle immagini degli ambienti di sviluppo del Machine Learning Workspace, è completamente gestita dal Workspace stesso.

Gestione DNS Allo scopo di associare domini personalizzati ai servizi, in particolare alla applicazione web, abbiamo creato una Azure DNS Zone, risorsa che assume il compito di gestire la propagazione dei record DNS del dominio utilizzato.

Abbiamo fatto la scelta di trasferire il controllo dei DNS ad Azure per automatizzare il processo di provisioning dei certificati: questo processo necessita della creazione di record DNS temporanei per autenticare la creazione del certificato, dato che Azure è in controllo dei record può generare e verificare i certificati senza intervento.

Gestione Log Per la gestione dei log generati dai vari componenti dell'infrastruttura abbiamo fatto uso del servizio Azure Log Analytics Workspace che offre una raccolta dei log centralizzata e mette a disposizione un linguaggio di query e altri strumenti per effettuare analisi sulle informazioni raccolte dai servizi.